

# 경쟁 후 협력: 프런티어 AI 교사가 검증 가능 커리큘럼으로 코딩 학생을 모방의 한계 너머로 향상시키다

(Compete then Collaborate)

Miseong (Shawn) Kim  
Genesis Cortex AI Inc.  
ORCID: 0009-0003-7566-3212

초안 v0.2 (동료검토 반영), 2026

**코드 · 데이터 · 테스트 · 검증 하네스:** <https://github.com/shawnkim678/compete-then-collaborate>  
본문의 모든 수치는 공개 산출물로 재계산하거나, 각자의 제공자 약관 하에 교사 풀이를 재생성하여 검증할 수 있다.

## Abstract

대규모 언어모델(LLM)은 점차 소형 학생(student) 모델의 학습 데이터를 생성하는 교사(teacher)로 활용되고 있다. 기존의 다중 교사 지식증류(knowledge distillation)는 여러 교사의 출력을 병합할 뿐, 어느 프런티어 모델이 가장 잘 가르치는가를 묻지 않으며, 자기 출력을 선호하는 편향이 알려진 LLM 심판에 의존하는 경우가 많다. 본 연구는 네 개 주요 연구소의 프런티어 AI 교사(Claude/Anthropic, Codex-GPT/OpenAI, Grok/xAI, Gemini/Google)를 먼저 실행 기반 심판(단위 테스트 / stdin-stdout 대조)과 공정성 통제(공유 태스크뱅크, 교사 자기교정, 교집합 통제 학습셋)로 **정면 비교**한 뒤, 이들이 **협력**하여 단일 코딩 학생(Qwen2.5-Coder)을 위한 검증 가능 커리큘럼을 구축하는 **경쟁 후 협력(competes-then-collaborate)** 프레임워크를 제안한다. 세 가지 발견을 보고한다. (1) 실행검증 하에서 네 교사 모두 자기교정 후 표준 문제를 거의 완벽하게( $\approx 99-100\%$ ) 푼다 — 이는 실력 차가 아니라 포화(saturation) 효과이다 — 반면 더 어려운 경쟁 문제에서는 서열이 드러난다(Gemini 77% > Claude 69%  $\approx$  Codex 69% > Grok 50%). 그럼에도 가장 견고한 결과는 학생 측에 있으며 교사 서열에 의존하지 않는다. (2) 교사의 검증된 풀이를 **모방(SFT)**하는 것은 이미 유능한 코딩 학생을 향상시키지 못하며 오히려 **저하시킬** 수 있다(7B-32B 모두; 예: MBPP-test 76.7% $\rightarrow$ 72.7%, 경쟁 문제 5.9% $\rightarrow$ 2.9%, 전체 교사 합집합 기준). (3) 동일한 협력 커리큘럼을 **검증가능보상강화학습(RLVR)** 환경으로 사용하면 학생이 오히려 **향상**된다(held-out 경쟁 문제에서 1000 스텝 학습 동안 5.9% $\rightarrow$ 8.8% 정점, 상대 +49%)—SFT와 방향이 반전된다. 본 연구의 핵심 주장은, AI 교사 협력의 가치가 답을 모아 모방시키는 데 있지 않고, 학생이 스스로 실행하며 배우는 검증 가능한 환경을 함께 구축하는 데 있다는 것이다. NVIDIA GB10 상에서 GRPO를 구동하기 위한 프레임워크 패치를 포함해 완전 재현 가능한 온프레미스 파이프라인을 공개한다.

## 1 서론

유능한 “교사” LLM을 소형 “학생” 모델로 증류하는 것은 이제 표준적 관행이다. 그러나 두 가지 질문이 충분히 탐구되지 않았다. (i) 어느 상용 프런티어 모델이 더 나은 교사인가 — LLM 심판이 아니라

학생의 실제 하위 성능으로 측정할 때; (ii) 여러 교사를 결합하는 최선의 방식은 답을 병합하는 것인가, 아니면 다른 기제가 있는가.

우리는 이를 파이썬 코딩에서 연구한다. 우리의 심판은 **코드 실행**이다 — 객관적이며, LLM 심판에서 문서화된 자기선호(self-preference) 편향으로부터 자유롭다. 먼저 **경쟁**을 수행한다: 교사들이 공유 태스크뱅크를 풀고, 교사의 출력은 히든 테스트를 통과할 때에만 학생의 데이터에 들어간다. 이어 **협력**을 수행한다: 교사들의 검증된 결과가 하나의 커리큘럼을 이루며, 이를 두 방식으로 사용한다 — 모방 목표(SFT)와 검증가능보상 강화학습 환경(RLVR).

**기여.** (1) 세 가지 공정성 통제(공유 태스크, 자기교정, 교집합)를 갖춘, 실행검증 기반의 편향 없는 **프런티어 AI 교사 서열화**. (2) 모방-SFT가 유능한 코딩 학생에게 실패/저하를 낳는 반면 검증가능보상 RL은 향상을 낳음을 보이는 **협력 방식의 통제 비교**. (3) transformers 5.5 / torch 2.11 / cu130에서 GRPO를 구동하기 위한 프레임워크 패치를 포함한 **재현 가능한 온프레미스(GB10) 파이프라인**.

## 2 관련 연구

**다중 교사 지식증류.** 선행 연구는 여러 교사의 근거(rationale)를 학생으로 병합하며, 교사를 무작정 늘리면 지식 충돌(knowledge conflict)로 인해 오히려 해로울 수 있어 정제/통합이 필요함을 보고한다 [3]. 우리의 합집합-SFT 결과는 이 저하를 독립적으로 재현하지만, 우리의 관점은 다르다: 우리는 모방을 위해 병합하지 않고 검증 가능한 환경을 구축한다.

**교사 선택 / LLM 심판.** 여러 연구가 Claude와 GPT를 “강한 교사”로 혼용하며, GPT-4가 평가 시 자기 생성물을 선호함을 경고한다 [5]. 우리는 실행으로 심판함으로써 이 편향을 제거한다.

**온-폴리시 증류 & RLVR.** 온-폴리시 증류 [1]와 대조적 증류 [4]는 모방을 개선하며, 검증가능보상 강화학습은 최근 추론 모델의 기반이 된다. 우리는 이를 연결한다: 교사들이 협력적으로 검증한 문제가 곧 RLVR의 보상 환경이 된다.

**가상/합성 데이터 기반 앙상블 학습(역사적 계보).** 가상(virtual)—합성 생성된—데이터로 학습한 앙상블이 개별 구성원을 능가할 수 있다는 직관은 딥러닝 시대 이전으로 거슬러 올라간다: Jang [2]는 1999년 POSTECH에서 가상 데이터 기반 앙상블 학습 알고리즘을 제안하였다. 우리의 설정은 같은 직관의 현대적 구현이다 — 앙상블 구성원은 프런티어 LLM 교사이며, “가상 데이터”는 실행검증된 합성 문제의 커리큘럼이다. 다만 이는 방법이 아니라 계보의 연결이다 — 1999년의 가상 데이터가 단일 예측기의 앙상블 다양성을 증대시킨 반면, 우리의 검증된 문제는 정책 최적화(RLVR)를 위한 보상 지형(reward landscape)을 정의한다. 따라서 우리는 본 연구를 그 계보의 정신적 후예로 위치시킨다: 앙상블 출력을 평균하지 않고, 협력적으로 검증된 커리큘럼을 강화학습 환경으로 사용한다는 점이 전환점이다.

**공백.** 실행검증으로 명명된 프런티어 모델을 교사로서 서열화하고, 모방 대 검증가능보상 협력을 대비하며, 이를 경쟁 후 협력 파이프라인으로 묶은 연구는 찾지 못했다.

## 3 방법

### 3.1 실행검증 생성(심판)

각 교사는 과제(함수 시그니처 또는 경쟁 문제)를 받아 추론과 하나의 코드 블록을 반환한다. 우리는 코드를 추출하여 격리된 서브프로세스(자원 제한 + 타임아웃)에서 **히든 테스트**(함수 과제는 단위 테스트 assert, 경쟁 과제는 stdin/stdout)로 실행한다. 테스트를 통과한 풀이만 채택한다. 따라서 정답성은 교사 모방이 아니라 실행에서 나온다.

### 3.2 공정성 통제를 갖춘 경쟁

(a) **공유 태스크뱅크** — 모든 교사가 동일 문제를 푼다(함수 시그니처 명시로 모호성 제거; 외부 의존 과제는 함수 단위 비교의 타당성을 위해 제외). (b) **자기교정** — 실패한 과제는 실패한 테스트 오류와 함께 최대 2회 교사에게 재제시하여, 답을 수정하는 교사를 모사한다(각 교사의 커버리지를 높이고 “한 번의 운” 교란을 제거). (c) **교집합 통제** — 학생 학습셋을 모든 교사가 푼 문제로 제한하여 동일 문제-동일 개수를 부여하므로, 오직 풀이/설명의 스타일만 달라진다.

### 3.3 협력: 한 학생을 위한 두 방식

모든 교사의 검증된 풀이의 **합집합**이 협력 커리큘럼을 이룬다. 이를 두 방식으로 사용한다: (**SFT**) 병합된 풀이를 모방; (**RLVR**) 검증된 문제를, 보상 = 통과 테스트 비율인 GRPO 보상 환경으로 취급. 학생 = Qwen2.5-Coder(주 7B, 보조 32B), LoRA.

## 4 실험 설정

- **학생**: Qwen2.5-Coder-7B / -32B, LoRA(bf16), GB10 128 GB 통합메모리.
- **교사**: Claude, Codex(GPT), Grok, Gemini(헤드리스 CLI; 4대 연구소 Anthropic, OpenAI, xAI, Google). Gemini는 실행검증 경쟁 서열에 참여하며, 협력 실험(SFT/RLVR)은 앞의 세 교사의 검증 풀이 합집합을 사용한다.
- **태스크뱅크**: MBPP의 함수 과제(교습 split; MBPP-test는 홀드아웃), MBPP 참조 풀이 변이(mutation)를 통한 버그픽스 과제; deepmind/code\_contests의 경쟁 문제(난이도 6-9).
- **홀드아웃 평가(누수 없음 검증)**: MBPP-test(150) 및 서로소인 경쟁 셋(68). 지표: 실행 pass@1.
- **RLVR**: TRL GRPOTrainer + PEFT(HF 경로; LoRA 자료형 버그로 Unsloth 커널 회피); 보상 = 테스트 통과 비율 + 소량의 형식 보너스; HF-generate 롤아웃(본 스택에서 vLLM 비호환).

## 5 결과

### 5.1 교사 경쟁(생성 pass@1)

쉬운 문제(MBPP, 공유 200문항) — 포화.

어려운 문제(code\_contests, 난이도 6-9, 150문항) — 정보량 있는 신호.

| 교사     | one-shot | 자기교정 후      |
|--------|----------|-------------|
| Claude | 96.5%    | <b>100%</b> |
| Grok   | 89.5%    | 99.5%       |
| Codex  | 90.0%    | 99.0%       |
| Gemini | 85.0%    | 99.5%       |

Table 1: 쉬운 MBPP는 포화 상태이다. 네 교사 모두 자기교정 후 99–100%에 도달하는데, 이는 실력이 아니라 벤치마크 노출을 반영할 가능성이 크다.

| 교사     | pass@1(정답)                        | 코드추출 성공                    |
|--------|-----------------------------------|----------------------------|
| Gemini | <b>77%</b> (115/150) <sup>‡</sup> | 100% <sup>‡</sup>          |
| Claude | 69% (104/150) <sup>§</sup>        | 96% (144/150)              |
| Codex  | 69% (103/150)                     | 90%                        |
| Grok   | 50% (75/150) <sup>†</sup>         | 73% (109/150) <sup>†</sup> |

Table 2: 어려운 경쟁 문제는 교사를 분리한다: Gemini > Claude  $\approx$  Codex > Grok. Gemini가  $\approx 8\%$ p 앞서며, Claude와 Codex는 한 문항 차이 안에 있다.

**해석(v0.2, 동료검토 반영).** MBPP의 천장 근접 점수(99–100%)는 벤치마크 포화 / 학습 노출을 반영할 가능성이 크며 —MBPP는 네 교사 모두가 접한 2021년 공개 벤치마크이다— **실력 차가 아니다.** 따라서 교사 서열을 MBPP에 근거하지 않는다.

더 어려운 code\_contests에서 교사는 더 뚜렷이 분리된다: **Gemini 선두(77%, 115/150), 이어 Claude(69%)  $\approx$  Codex(69%), 그리고 Grok(50%).** 어려운 문제에서 특정 공급자의 모델이 유일하게 최고인 것은 아니다. Gemini가  $\approx 8\%$ p 앞서고 Claude와 Codex는 한 문항 차이 안에 있다. 결정적으로 이 서열은 어떤 LLM 심판도 아닌 실행만으로 산출되므로 자기선호/패밀리 편향이 설계상 배제된다. 잔여 위험은 비대칭적 학습누수와 CLI/파서 아티팩트이며, 이는 7절에서 다룬다.

**공정성 보정.** 우리는 실력 차가 아닌 세 가지 인프라 아티팩트를 발견·보정하였으며, 각 교사에 동일하게 적용하고 투명하게 보고한다:

- **§ Claude** — 첫 실행이 122/150에서 중단되었다. 남은 28문항을 완료하여(22 통과) 모든 교사를 동일한 150문항으로 채점하였고, Claude는 공정한 **69%(104/150)**가 된다(중단 실행의 67%(82/122)에서 상승).
- **‡ Gemini** — 생성 도중 API 선불 크레딧이 소진되어 마지막 34/150문항이 과금 오류(429)로 무응답 처리되었다. 크레딧 복구 후 그 34문항만 재실행·병합하였다: **77%(115/150)**, 코드추출 100%.
- **† Grok** — 초기에 배치 CLI 호출의 52%가 빈 응답(타임아웃/불안정, 오답 아님)이었다. 빈응답 재시도를 추가하여 재측정하였다: **50%(75/150)**, 추출 48%→73%(109/150). 재시도 후에도 27%(41/150)는 사용가능 코드를 내지 못했는데, CLI 불안정과 실제 난이도를 완전히 분리할 수

없이 폐기하지 않고 투명하게 보고한다. 따라서 Grok-Codex/Claude 격차(50% 대 69%)는 보수적(Grok에 유리한) 추정이다.

## 5.2 협력 방식 A — 모방(SFT)은 유능한 학생을 돕지 못한다

홀드아웃 pass@1(교집합 통제, 공유 197문항):

| 학생         | base  | +Claude | +Codex | +Grok |
|------------|-------|---------|--------|-------|
| 7B (MBPP)  | 76.7% | 74.0%   | 70.0%  | 69.3% |
| 32B (MBPP) | 82.0% | 80.0%   | 77.3%  | 79.3% |

Table 3: 모든 SFT 학생이 base 이하로 떨어진다. 교사 서열은 보존된다(Claude가 가장 덜 해롭다).

모든 학생이 **base 이하**로 떨어지며, 교사 서열은 보존된다(Claude가 가장 덜 해롭다). 전체 교사 **합집합(SFT)** 역시 base 이하이다(MBPP 72.7%, 경쟁 **2.9%** 대 base 5.9%).

이 규모의 모방은 이미 유능한 코딩 모델을 저하시키며, 병목은 모델 크기가 아니라 과제의 난이도/여지이다 — 7B와 32B 모두 저하된다.

## 5.3 협력 방식 B — 검증가능보상 강화학습(RLVR)은 학생을 향상시킨다

동일 커리큘럼, 경쟁 홀드아웃(base가 약해 여지가 큼):

| 방식                             | 경쟁 base→학생                         | 방향                  |
|--------------------------------|------------------------------------|---------------------|
| SFT(합집합)                       | 5.9% → 2.9%                        | ↓ 저하                |
| RLVR(GRPO, 200 스텝)             | 5.9% → 7.4%                        | ↑ 상대 +25%           |
| <b>RLVR(GRPO, v2, 1000 스텝)</b> | 5.9% → <b>8.8%</b> 정점(1000에서 7.4%) | ↑ <b>정점 상대 +49%</b> |

Table 4: 동일 데이터, 반대 방향: 모방은 저하시키고 검증가능보상 RL은 향상시킨다. v2 1000 스텝은 250-750 스텝에서 8.8% 정점을 이루고 후반에 7.4%로 완만히 회귀한다.

학습 보상은 초기  $\approx 0$ 에서 후반 0.25-1.0로 상승하였고(학습셋 일반화), 홀드아웃도 향상되었다. **동일 데이터, SFT와 반대 방향이다.**

# 6 논의

결과는 명료한 메시지를 준다: **AI 교사 협력의 가치는 답을 모아 모방시키는 데 있지 않고, 학생이 스스로 실행하며 배우는 검증 가능한 환경을 함께 구축하는 데 있다.** 모방은 유능한 코더가 이미 가진 스타일을 전달할 뿐이나, RLVR은 검증된 성공에 보상함으로써 능력을 전달한다. 이는 재현된 다중 교사 KD 저하(지식 충돌)도 설명한다: 답을 병합하는 것은 학생의 모방 상한을 넘을 수 없으나, 검증가능보상에 대한 RL은 이를 넘을 수 있다.




Figure 1: v2 학습곡선(1000 스텝). 좌/파랑: 로그된 학습 보상(평균), 0.22 →  $\approx 0.43$  상승 후 정체. 우/빨강: 경쟁 68문항에 대한 체크포인트별 held-out pass@1 — base 5.9%(4/68)에서 250–750 스텝의 8.8%(6/68) 정체까지 상승, 1000 스텝에서 7.4%(5/68)로 완만히 회귀. 정체 구간 내 차이는 68문항 중  $\pm 1$ 문항(표집 노이즈)에 해당하며, 견고한 신호는 base → RLVR(4 → 5–6/68)이다.

## 7 한계

- **벤치마크 포화 / 학습 누수.** MBPP는 널리 알려진 2021년 벤치마크로, 교사의 천장 근접 점수(99–100%)는 실력 차보다 학습셋 노출을 반영할 가능성이 크며, 따라서 안정적 서열 논의는 더 어려운 code\_contests 부분집합에 근거한다. 개별 테스트 항목이 특정 교사의 사전학습 코퍼스에 그대로 존재하는지는 검증하지 않았으며, 교사 간 비대칭 누수가 있다면 서열에 편향을 줄 수 있다.
- **프롬프트/파서/CLI 대칭성.** 모든 교사가 하나의 프롬프트 템플릿과 하나의 코드추출 파서를 공유한다. Grok의 배치 CLI가 어려운 문제 호출의 52%에서 빈 응답을 낸(타임아웃/불안정, 오답 아님) 공정성 아티팩트를 발견·보정하였으며, 빈응답 재시도를 추가하여 비교를 공정하게 하였다. 잔여 형식 우위가 있더라도 공유 파서와 보고된 추출 성공률로 그 범위가 제한된다.
- **교사 서열은 학생 측 결과보다 약하다.** 어려운 부분집합에서 Gemini가  $\approx 8\%$ p 앞서고 Claude  $\approx$  Codex(한 문항 차이)이며 Grok이 뒤진다. Gemini 아래의 세부 순서는 표본 크기를 고려하면 약하게만 분리된다. 반면 **SFT 실패 / RLVR 성공의 반전은 견고하다:** 이는 학생의 홀드아웃 성능 변화이며 교사 서열이나 어떤 LLM 심판에도 의존하지 않는다.
- RLVR의 향상폭은 희소한 경쟁 보상 하에서 절대적으로는 완만하다. 1000 스텝 v2 실행은 홀드아웃 pass@1을 base 5.9%에서 8.8% 정체(250–750 스텝)로 향상시키고 1000 스텝에서 7.4%로 완만히 회귀한다. 홀드아웃이 68문항뿐이라 정체 구간 내 차이( $\pm 1$ 문항)는 표집 노이즈 안에 있으므로, 정확한 정점보다 견고한 방향(base → RLVR, 4 → 5–6/68)을 보고하며 최종 스텝 대신 체크포인트 선택을 권장한다. 더 큰 홀드아웃은 이 추정을 더 정밀하게 할 것이다.
- 단일 학생 계열(Qwen2.5-Coder), 단일 언어(Python).
- **윤리 / 이용약관.** 본 연구는 **학술 연구**(벤치마킹·방법론 연구)이며, 어떤 공급자와도 경쟁하는

상용 모델의 개발·배포·증류가 아니다; 어떤 학습 모델도 제품으로 제공하지 않는다. 이 목적은 본 연구를 Anthropic(경쟁 제품/경쟁 모델 학습 금지) 및 OpenAI(OpenAI와 경쟁하는 모델 금지)의 경쟁 범위 제한 밖에 둔다; Google Gemini 약관도 마찬가지로 경쟁 범위로 한정된다. 우리는 추가로 (i) 어떤 교사의 원시 출력도 재배포하지 **않으며**, (ii) 교사 출력으로 학습한 모델을 공개하지 **않고**, (iii) 핵심 RLVR 결과를 실행 보상과 공개 경쟁 문제에 기반하여 **교사 출력 증류 없이** 도출한다—이는 xAI의 출력 증류에 대한 행위 범위 제한도 함께 해소한다. 정당성은 교사 모방이 아니라 결정적 실행으로 심판되며, 공개된 태스크/테스트/하네스를 통해 누구든 모든 수치를 오프라인(공개 산출물 재검증)으로 또는 각자의 공급자 약관 하에서 교사 풀이를 재생성하여 재현할 수 있다.

- 하드웨어: 장시간 RLVR 중 GPU GSP 타임아웃(Xid 119/154)으로 재부팅이 필요했으며, 롤아웃 강도 완화·체크포인트·Xid 감시로 대응한다.

## 8 결론

프런티어 AI는 편향 없는 실행 기반 심판으로 교사로서 서열화될 수 있으며, 더 중요하게는 그들의 협력이 강화학습용 검증 가능 커리큘럼으로 표현될 때 모방이 실패하는 지점에서 코딩 학생을 실제로 향상시킨다. 우리는 NVIDIA GB10에서 이를 재현하기 위한 전체 온프레미스 파이프라인과 프레임워크 패치를 공개한다.

## 재현성

모든 코드·태스크뱅크·히든 테스트·결과 및 본 논문은 <https://github.com/shawnkim678/compete-then-collaborate>에 공개한다. 독자는 보고된 모든 수치를 오프라인(`python reproduce.py --check-banks --selftest`)으로 재검증하거나, 각자의 API 키와 공급자 약관 하에서 교사 풀이를 재생성할 수 있다; 우리는 어떤 교사 출력도 재배포하지 않는다(윤리 진술 참조).

스크립트: `verify_code.py`, `verify_stdio.py`, `build_taskbank_mbpp.py`, `build_contests_bank.py`, `prof_run.py`, `prof_run_stdio.py`, `prof_retry.py`, `equalize_golden.py`, `eval_code_students.py`, `grpo_train.py`. 오케스트레이션(`setid`): `grpo_orchestrator.sh`. GB10 프레임워크 패치(`trl import` 플래그, `vLLM off`, `PreTrainedModel.warnings_issued`, Unsloth LoRA-자료형 버그 회피를 위한 `HF+PEFT`)는 연구 로그 § 16–17에 문서화되어 있다.

## 감사의 글

가상 데이터 기반 앙상블 학습에 관한 1999년 학위논문 [2]으로 본 연구의 검증가능 커리큘럼 관점에 개념적 계보를 제공하고 연구 방향에 조언을 주신 장민(Min Jang) 박사 (포항공과대학교, POSTECH)께 감사드린다. 본 논문에는 어떤 제3자 저작물도 재배포되지 않으며, 해당 학위논문은 서지적으로만 인용된다.

## References

- [1] Yuxian Gu, Li Dong, Furu Wei, and Minlie Huang. MiniLLM: Knowledge distillation of large language models. In International Conference on Learning Representations (ICLR), 2024.
- [2] Min Jang. Ensemble Learning Algorithm using Virtual Data. Ph.D. dissertation, Pohang University of Science and Technology (POSTECH), Pohang, Republic of Korea, November 1999. Advisor: Cheeha Kim.
- [3] Ruihan Jin, Pengpeng Shao, Zhengqi Wen, Jinyang Wu, Mingkuan Feng, Shuo Yang, Chu Yuan Zhang, and Jianhua Tao. Exploring knowledge purification in multi-teacher knowledge distillation for LLMs. In International Conference on Learning Representations (ICLR), 2026. Reports that distillation performance can decline as the number of teacher LLMs grows (knowledge conflict), motivating rationale purification.
- [4] Jongwoo Ko, Tianyi Chen, Sungnyun Kim, Tianyu Ding, Luming Liang, Ilya Zharkov, and Se-Young Yun. DistiLLM-2: A contrastive approach boosts the distillation of LLMs. arXiv preprint arXiv:2503.07067, 2025.
- [5] Nathan Lambert. Reinforcement Learning from Human Feedback: Alignment and Post-Training of LLMs. Manning Publications, 2025. ISBN 9781633434301. Also available as arXiv:2504.12501. Discusses LLM-as-judge self-preference bias (ch. 12).